Automatisierbar

Ressourcen · 6. November 2026

Chinesische KI in deiner Firma – sicher und günstig

Warum grosse Firmen auf offene Modelle wechseln, wie du das passende Modell findest und wie du eine KI ohne Internet auf deinem eigenen Rechner laufen lässt.

Das günstigste Modell, das reicht

Die 4 Schritte aus dem Video: So findest du für jede Aufgabe das Modell, das gut genug ist, und brauchst vielleicht gar keinen Anbieter mehr.

1 Weiche bauen: eine Stelle, an der du mit einem Klick das Modell wechselst
2 Mit dem klügsten Modell starten, dann eine Generation zurück, solange es klappt
3 Liegt die Grenze unter dem besten offenen Modell: herunterladen und selbst laufen lassen

OpenRouter-Rangliste ansehen

1 · DIE 3 GRÜNDE AUS DEM VIDEO

1 Preis
Gleiche Arbeit, halbe Rechnung: 1,6 Mrd. Tokens in 30 Tagen hätten mit Claude Opus über die Schnittstelle 924 $ gekostet, mit Kimi 447 $.

2 Kontrolle
Heruntergeladene Modelle laufen bei dir im Haus. Deine Daten gehen weder nach China noch zu einem anderen Anbieter. Wichtig: In der Kimi- oder Qwen-App gehen sie sehr wohl nach China.

3 Unabhängigkeit
Mit einem eigenen Modell kann dir niemand die Preise erhöhen, ein Modell abschalten oder den Stecker ziehen.

2 · KI OHNE INTERNET AUF DEM EIGENEN RECHNER

LM Studio (einfachster Weg)
App installieren, offenes Modell (z. B. Qwen) herunterladen, WLAN aus, chatten. Für einen Mac mit 24 GB reichen Modelle bis ~27 Mrd. Parameter in komprimierter Form.
lmstudio.ai →

Ollama (für Bastler)
Läuft im Hintergrund und bietet eine Schnittstelle wie OpenAI, an die du eigene Abläufe hängen kannst.
ollama.com →

Offene Modelle finden
Qwen (Alibaba), Kimi (Moonshot), DeepSeek, GLM (Zhipu) liegen frei auf Hugging Face.
huggingface.co/Qwen →
huggingface.co/moonshotai →

Prompt: Mein lokales KI-Setup
Gib das Claude, ChatGPT oder Codex, damit es dich durch die Einrichtung führt.

```
Ich will ein offenes KI-Modell (z. B. Qwen) lokal auf meinem Rechner laufen lassen, ohne dass Daten ins Internet gehen. Mein Rechner: [Modell, Prozessor, Arbeitsspeicher]. Empfiehl mir das grösste Modell, das flüssig läuft, und die passende Komprimierung. Führe mich Schritt für Schritt durch Installation und ersten Test. Zeig mir am Schluss, wie ich prüfe, dass wirklich keine Verbindung ins Internet besteht.
```

3 · DER TEST AUS DEM VIDEO

Prompt: Offerte mit interner Preisformel
Genau dieser Auftrag lief im Video auf dem Mac mini mit Qwen, Internet aus. Ergebnis: CHF 4'371.56, richtig gerechnet.

```
Unsere interne Preisformel: Arbeitsstunde 95 Franken, Material plus 18 % Zuschlag, dazu 8,1 % Mehrwertsteuer. Schreibe eine kurze Offerte an Frau Meier: neue Küchenfront, 12 Türen, 14 Stunden Arbeit, Material 2300 Franken. Zeige die Rechnung Schritt für Schritt.
```

Prompt: Modell-Leiter für deine Aufgabe
Schritt 2 bis 4 aus dem Video als Prompt für deinen Test.

```
Ich will für diese Aufgabe das günstigste Modell finden, das gut genug ist: [Aufgabe + 3 echte Beispiele]. Lege zuerst fest, woran wir 'gut genug' messen. Teste dann mit dem stärksten Modell, danach je eine Generation älter bzw. günstiger, und am Schluss mit den besten offenen Modellen (Qwen, Kimi, DeepSeek). Gib mir eine Tabelle: Modell, Kosten pro 1000 Aufgaben, Qualität, bestanden ja/nein.
```

QUELLEN AUS DEM VIDEO

Chinesische Modelle weltweit, OpenRouter-Anteil, Lindy
CNBC, 26.09.2026
cnbc.com →

Coinbase halbiert KI-Ausgaben (Kimi + GLM)
Fortune, 26.07.2026
fortune.com →

Warum Amerikaner chinesische KI wählen
Rest of World
restofworld.org →

Kimi K3.1 Pro: Tests und Preise
Artificial Analysis
artificialanalysis.ai →

OpenRouter-Rangliste
Welche Modelle gerade am meisten genutzt werden
openrouter.ai/rankings →

Fehlt etwas?
Frag in der Community.

Fragen zum Video? Wir helfen dir in der Community, gratis.

Zur Community | Alle Ressourcen